Laboratório 2: Processamento de Bases de Dados em Lote

Author
Noemi Leone

Compilação do arquivo:

```
Sys.setenv(TZ = "America/Sao_Paulo")

data_compilacao <- format(
  Sys.time(),
  format = "%d/%m/%Y %H:%M:%S",
  tz = "America/Sao_Paulo"
)
data_compilacao
```

```
[1] "25/08/2026 02:19:46"
```

Instalação e carregamento de pacotes:

```
library(dplyr)
```

```

Anexando pacote: 'dplyr'

Os seguintes objetos são mascarados por 'package:stats':

    filter, lag

Os seguintes objetos são mascarados por 'package:base':

    intersect, setdiff, setequal, union
```

```
library(readr)
library(ggplot2)
library(ggmap)
```

```
ℹ Google's Terms of Service: <https://mapsplatform.google.com>
  Stadia Maps' Terms of Service: <https://stadiamaps.com/terms-of-service>
  OpenStreetMap's Tile Usage Policy: <https://operations.osmfoundation.org/policies/tiles>
ℹ Please cite ggmap if you use it! Use `citation("ggmap")` for details.
```

```
library(tibble)
library(lubridate)
```

```

Anexando pacote: 'lubridate'

Os seguintes objetos são mascarados por 'package:base':

    date, intersect, setdiff, union
```

Laboratório 2: Processamento de Bases de Dados em Lote

Instrução 01 - Estatísticas suficientes

Para calcular o percentual de voos que apresentaram atraso superior a 10 minutos, são necessárias duas estatísticas:

- o número total de voos;
- o número de voos cujo `ARRIVAL_DELAY` é superior a 10 minutos.

O percentual de atrasos pode então ser calculado por:

$$Perc = \frac{\text{número de voos atrasados}}{\text{número total de voos}}$$

Essas estatísticas serão calculadas separadamente para cada combinação de dia, mês e companhia aérea.

Instrução 02 - Função getStats()

```
getStats <- function(input, pos) {

  input %>%
    filter(
      AIRLINE %in% c("AA", "DL", "UA", "US")
    ) %>%
    filter(
      !is.na(AIRLINE),
      !is.na(DAY),
      !is.na(MONTH),
      !is.na(ARRIVAL_DELAY)
    ) %>%
    group_by(
      DAY,
      MONTH,
      AIRLINE
    ) %>%
    summarise(
      total = n(),
      atrasados = sum(ARRIVAL_DELAY > 10),
      .groups = "drop"
    )
}
```

Instrução 03 - Importação do arquivo flights.csv.zip

```
callback <- DataFrameCallback$new(getStats)
stats_lotes <- read_csv_chunked(
  "flights.csv.zip",
  callback = callback,
  chunk_size = 100000,
  col_types = cols_only(
    AIRLINE = col_character(),
    DAY = col_integer(),
    MONTH = col_integer(),
    ARRIVAL_DELAY = col_double()
  ),
  progress = FALSE
)
```

Instrução 04 - Função computeStats

```
computeStats <- function(stats) {

  stats %>%
    group_by(
      DAY,
      MONTH,
      AIRLINE
    ) %>%
    summarise(
      total = sum(total),
      atrasados = sum(atrasados),
      .groups = "drop"
    ) %>%
    mutate(
      Cia = AIRLINE,
      Data = make_date(
        year = 2015,
        month = MONTH,
        day = DAY
      ),
      Perc = atrasados / total
    ) %>%
    select(
      Cia,
      Data,
      Perc
    )
}


stats <- computeStats(stats_lotes)
head(stats)
```

```
# A tibble: 6 × 3
  Cia   Data        Perc
  <chr> <date>     <dbl>
1 AA    2015-01-01 0.373
2 DL    2015-01-01 0.0047
3 UA    2015-01-01 0.289
4 US    2015-01-01 0.196
5 AA    2015-02-01 0.201
6 DL    2015-02-01 0.003
```

Instrução 05 - Mapa de calor por cia Aérea

Executando base do calendário:

```
pal <- scale_fill_gradient(
  low = "#457b54",
  high = "#d73027",
  na.value = "grey90"
)


baseCalendario <- function(stats, cia) {
  dados_cia <- stats %>%
    filter(Cia == cia)


  calendario <- dados_cia %>%
    mutate(
      dia_semana = wday(Data),
      semana = week(Data),
      mes = month(Data, label = TRUE, abbr = TRUE)
    )


  base_plot <- ggplot(calendario, aes(x = dia_semana, y = semana, fill = Perc)) +
    geom_tile(color = "white", size = 0.5) +
    facet_wrap(~mes, scales = "free") +
    scale_y_reverse() +
    labs(
      title = paste("Percentual de Atrasos -", cia),
      x = "Dia da Semana",
      y = "Semana",
      fill = "% Atraso"
    ) +
    theme_minimal() +
    theme(
      axis.text.x = element_text(angle = 45, hjust = 1),
      strip.background = element_rect(fill = "lightgray"),
      panel.grid = element_blank()
    )

  return(base_plot)
}
```

Executando calendário de cada linha aérea:

```
CAA <- baseCalendario(stats, "AA")
```

```
Warning: Using `size` aesthetic for lines was deprecated in ggplot2 3.4.0.
ℹ Please use `linewidth` instead.
```

```
CDL <- baseCalendario(stats, "DL")
CUA <- baseCalendario(stats, "UA")
CUS <- baseCalendario(stats, "US")
```

###American Airlines

```
print(CAA + pal + labs(title = "American Airlines (AA) - Percentual de Atrasos 2015"))
```

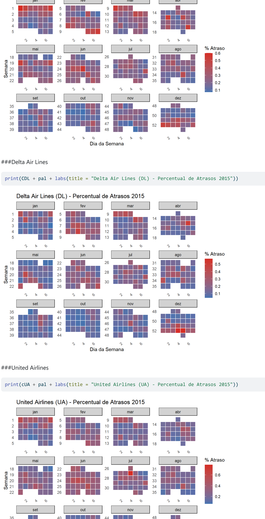

###Delta Air Lines

```
print(CDL + pal + labs(title = "Delta Air Lines (DL) - Percentual de Atrasos 2015"))
```


###United Airlines

```
print(CUA + pal + labs(title = "United Airlines (UA) - Percentual de Atrasos 2015"))
```

###US Airways

```
print(CUS + pal + labs(title = "US Airways (US) - Percentual de Atrasos 2015"))
```