Laboratório 09: Visualização de Dados com plotnine

AUTHOR
Noemi de Souza Leone

Configurações de horários

```
Sys.setenv(TZ = "America/Sao_Paulo")
data_hora <- format(Sys.time(), "%d/%m/%Y às %H:%M:%S")
data_hora
```

Atividade 1: Importação dos dados

```
import pandas as pd
from IPython.display import display
from plotnine import (
    ggplot, aes, geom_point, geom_smooth,
    facet_wrap, facet_grid, labs,
    theme_minimal, theme, element_text
)
import pandas as pd
from plotnine import (
    ggplot, aes, geom_point, geom_smooth, facet_wrap, facet_grid,
    labs, theme_minimal, theme, element_text, scale_y_continuous
)

diamonds = pd.read_csv("diamonds.csv.gz")

# Conferir as primeiras linhas, dimensões e tipos das variáveis
display(diamonds.head())
print("Dimensões do conjunto:", diamonds.shape)
print(diamonds.dtypes)
```

	carat	cut	color	clarity	depth	table	price	x	y	z
0	0.23	Ideal	E	SI2	61.5	55.0	326	3.95	3.98	2.43
1	0.21	Premium	E	SI1	59.8	61.0	326	3.89	3.84	2.31
2	0.23	Good	E	VS1	56.9	65.0	327	4.05	4.07	2.31
3	0.29	Premium	I	VS2	62.4	58.0	334	4.20	4.23	2.63
4	0.31	Good	J	SI2	63.3	58.0	335	4.34	4.35	2.75

```
Dimensões do conjunto: (53940, 10)
carat      float64
cut            str
color          str
clarity        str
depth      float64
table      float64
price        int64
```

```
x          float64
y          float64
z          float64
dtype: object
```

O conjunto possui 53.940 observações e 10 variáveis. `carat` e `price` são numéricas; `cut`, `color` e `clarity` são categóricas.

Vamos verificar se há valores ausentes e conferir as categorias:

```
print("Valores ausentes por variável:")
display(diamonds.isna().sum())

print("Categorias de corte:", sorted(diamonds["cut"].unique()))
print("Categorias de cor:", sorted(diamonds["color"].unique()))
print("Categorias de clareza:", sorted(diamonds["clarity"].unique()))
```

```
Valores ausentes por variável:

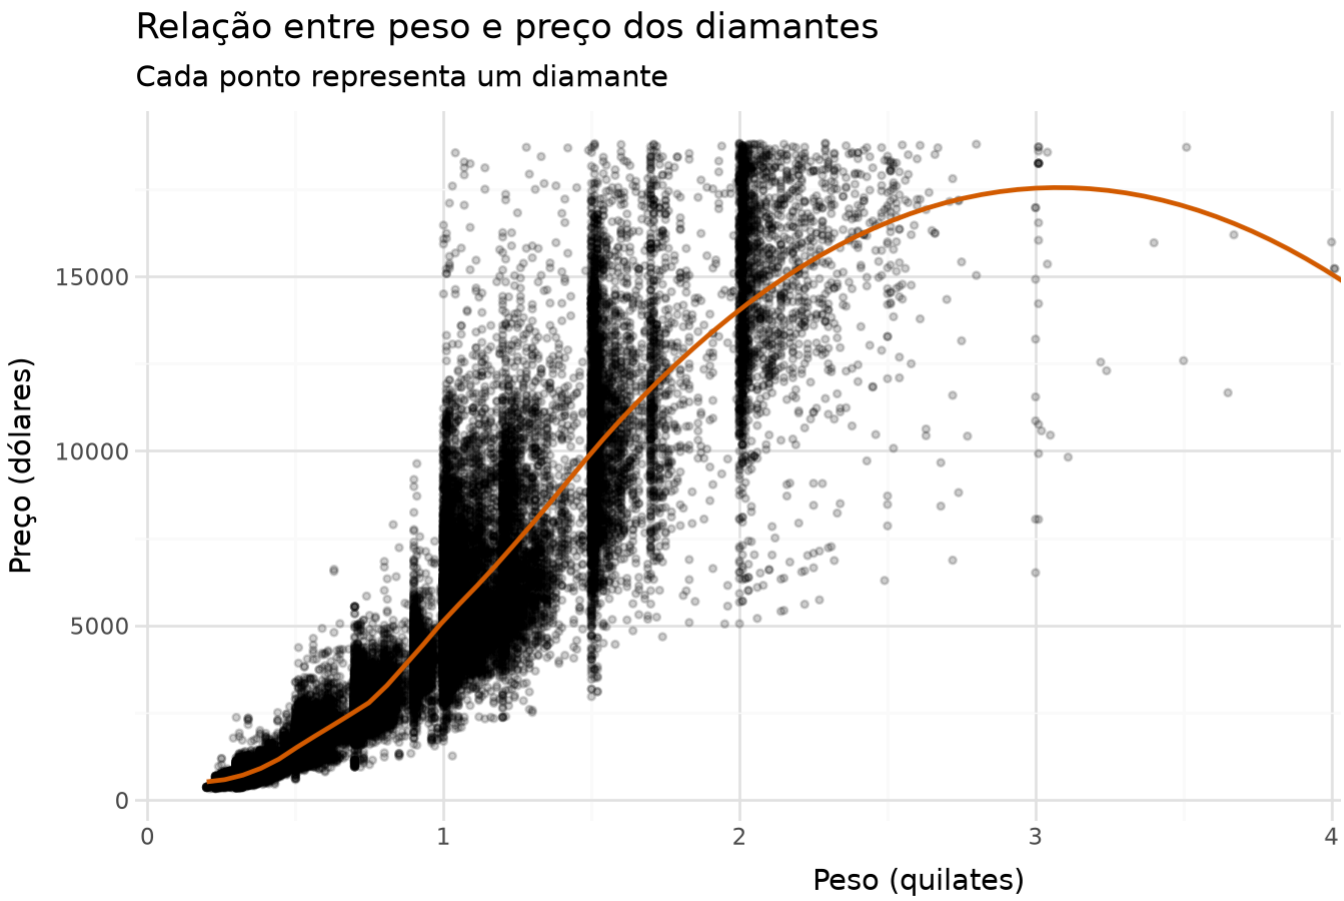
carat      0
cut        0
color      0
clarity    0
depth      0
table      0
price      0
x          0
y          0
z          0
dtype: int64

Categorias de corte: ['Fair', 'Good', 'Ideal', 'Premium', 'Very Good']
Categorias de cor: ['D', 'E', 'F', 'G', 'H', 'I', 'J']
Categorias de clareza: ['I1', 'IF', 'SI1', 'SI2', 'VS1', 'VS2', 'VVS1', 'VVS2']
```

Atividade 02: Relação entre peso (`carat`) e preço (`price`)

```
grafico_1 = (
    ggplot(diamonds, aes(x="carat", y="price"))
    + geom_point(alpha=0.18, size=1)
    + geom_smooth(method="loess", se=False, color="#D55E00", span=0.5)
    + labs(
        title="Relação entre peso e preço dos diamantes",
        subtitle="Cada ponto representa um diamante",
        x="Peso (quilates)",
        y="Preço (dólares)",
        caption="Fonte: conjunto de dados diamonds"
    )
    + theme_minimal()
    + theme(figure_size=(9, 5))
```

```
)
grafico_1
```

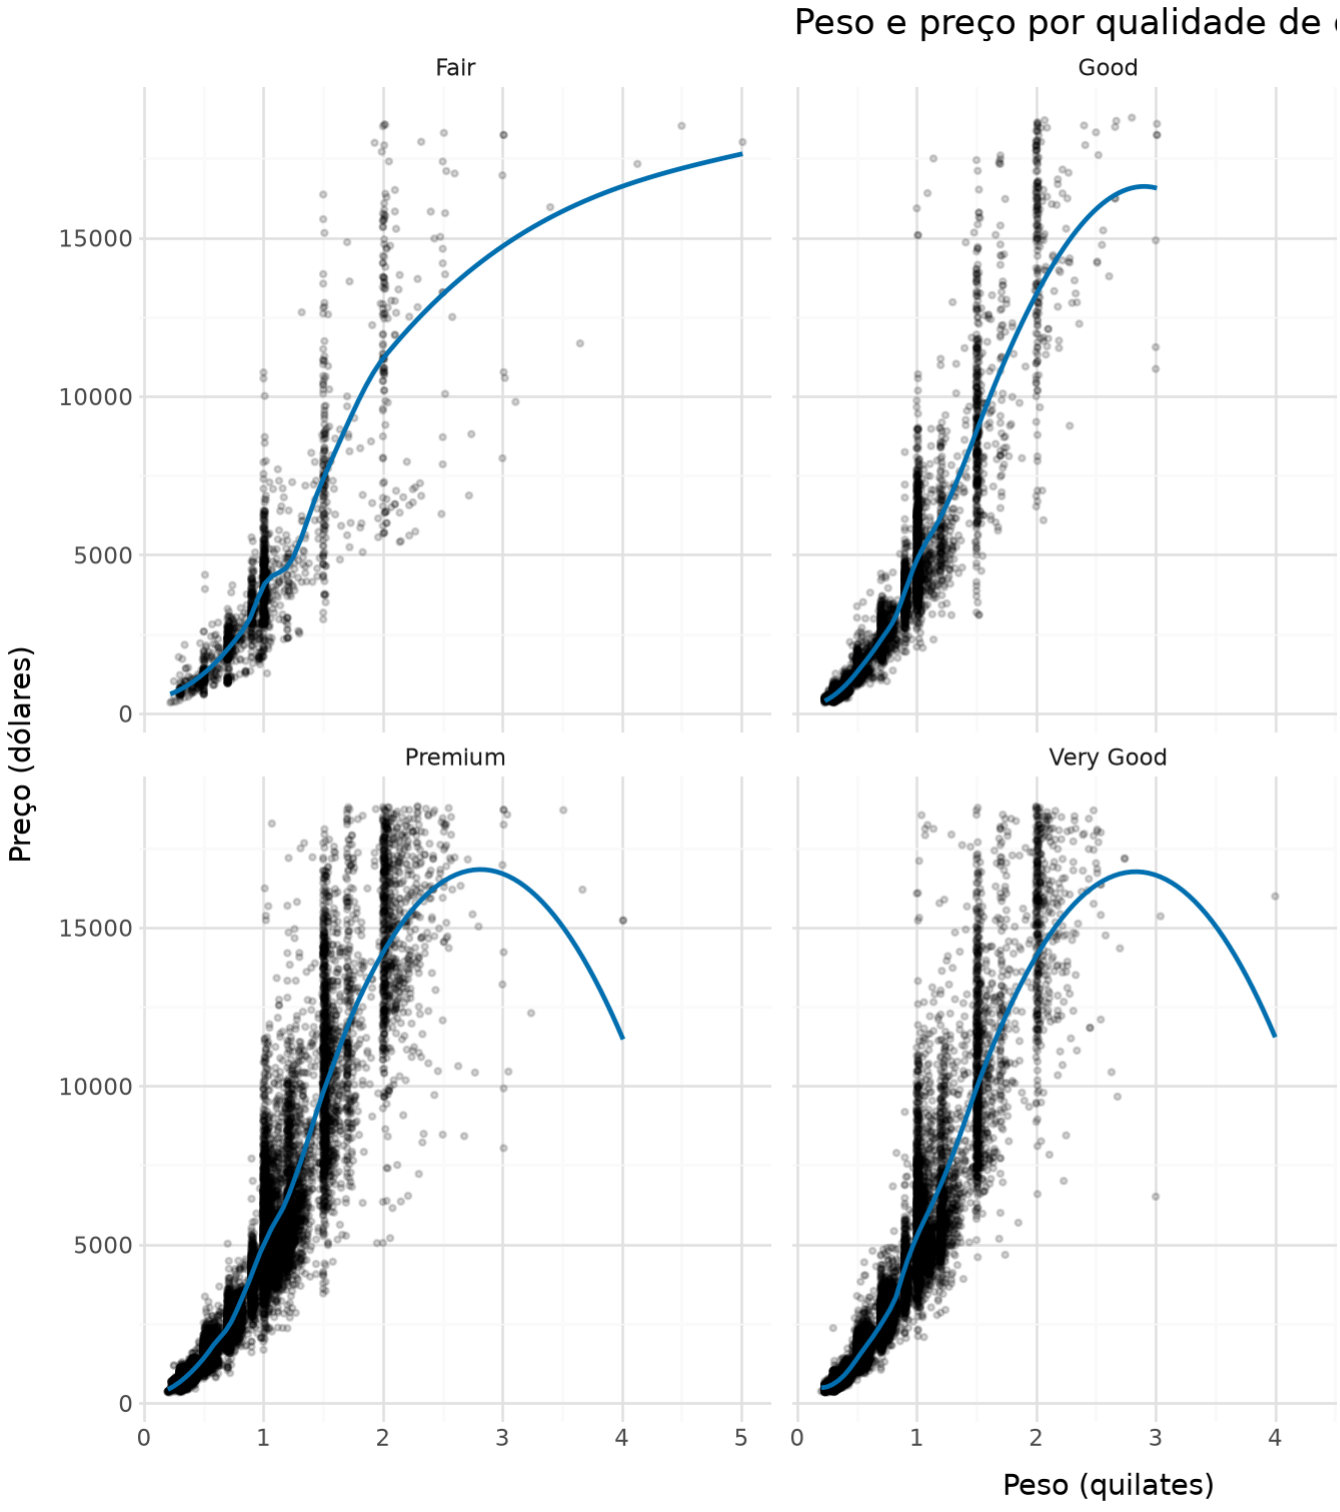


Atividade 03: A relação entre peso e preço é igual para todos os cortes?

Para comparar os tipos de corte, vamos separar o gráfico em painéis. Assim, cada categoria de `cut` terá seu próprio painel, mantendo a mesma escala para facilitar a comparação.

```
grafico_2 = (
    ggplot(diamonds, aes(x="carat", y="price"))
    + geom_point(alpha=0.16, size=0.8)
    + geom_smooth(method="loess", se=False, color="#0072B2", span=0.5)
    + facet_wrap("~cut", ncol=3)
    + labs(
        title="Peso e preço por qualidade de corte",
        x="Peso (quilates)",
        y="Preço (dólares)"
    )
    + theme_minimal()
    + theme(figure_size=(11, 8), subplots_adjust={"wspace": 0.15, "hspace": 0.25})
)
grafico_2
```

```
C:\Users\vivia\AppData\Local\R\cache\R\reticulate\uv\cache\archive-v0\A--Dp-9j1ruSOg-
W\Lib\site-packages\plotnine\themes\themeable.py:2486: FutureWarning: You no longer need to
use subplots_adjust to make space for the legend or text around the panels. This parameter
will be removed in a future version. You can still use 'plot_margin' 'panel_spacing' for your
other spacing needs.
```



Concluimos que os gráficos permitem explorar a associação entre peso e preço e comparar como ela se apresenta em diferentes categorias de corte, cor e clareza. O uso de transparência reduz a sobreposição dos pontos; os painéis facilitam a comparação entre categorias; e as curvas suavizadas ajudam a visualizar tendências que podem não ser lineares. Ao mesmo tempo, o grande número de observações

e categorias dificulta a leitura de algumas comparações. Portanto, as visualizações ajudam a identificar padrões, mas não demonstram, por si só, causalidade nem a significância estatística das diferenças.